

B2B31CZS/BD5B31CZS

Číslicové zpracování signálů

Vzorkování spojitých signálů

Základní vlastnosti diskrétních signálů

Doc. Ing. Petr Pollák, CSc.



23. září 2025 - 13:28

Část I

Spojité a diskrétní signály

Reprezentace spojitých signálů

Signál $x(t)$... proměnná 'x' závislá na čase 't'





$x(t)$... reprezentace v časové oblasti (časový průběh)

$X(j\omega)$... reprezentace ve frekvenční oblasti (spektrum)

$$X(j\omega) = \int_{-\infty}^{\infty} x(t)e^{-j\omega t} dt \quad \omega = 2\pi f$$

... Fourierova transformace (obecného spojitého signálu)

Vzorkování spojitého signálu



$x[n]$... diskrétní signál (posloupnost vzorků)

$x[n] = x(nT_s)$ pro $n = -\infty, \dots, -1, 0, 1, 2, \dots, \infty$

T_s ... vzorkovací perioda $f_s = \frac{1}{T_s}$... vzorkovací frekvence

n ... diskrétní čas (celočíselná hodnota !!)

Spektrum diskrétního signálu

$$X(j\omega) = \int_{-\infty}^{\infty} x(t)e^{-j\omega t} dt$$

$x(t)$... spojitý signál

$\omega = 2\pi f$... úhlová frekvence

Pro signál $x(t)$ vzorkovaný s periodou T_s (vzorkovací frekvencí f_s)

$$x(t) \rightarrow x(nT_s)$$

$$\int_{-\infty}^{\infty} \rightarrow \sum_{n=-\infty}^{\infty}$$

$$t \rightarrow nT_s, \quad dt = T_s$$

$\Rightarrow$

$$X(j\omega) = T_s \sum_{n=-\infty}^{\infty} x(nT_s)e^{-j\omega nT_s}$$

Normalizovaná (Nyquistova) frekvence :

$$\theta = \omega T_s = 2\pi f T_s = 2\pi \frac{f}{f_s}$$

$$f = \frac{f_s}{2} \approx \theta = \pi$$

$$f = -\frac{f_s}{2} \approx \theta = -\pi$$

$$X(j\omega) \rightarrow X(e^{j\theta})$$

$$x(nT_s) \rightarrow x[n]$$

DTFT - Discrete-Time Fourier Transform

- Fourierova transformace diskrétního signálu

$$X(e^{j\theta}) = \sum_{n=-\infty}^{\infty} x[n]e^{-j\theta n}$$

Spektrum diskrétního signálu - periodicitá

DTFT - Discrete-Time Fourier Transform

$$X(e^{j\theta}) = \sum_{n=-\infty}^{\infty} x[n]e^{-j\theta n}, \quad \theta = \omega T_s = 2\pi f T_s$$

Hodnota spektra na frekvenci f :

$$X(f) = \sum_{n=-\infty}^{\infty} x[n]e^{-j2\pi f T_s n} = \sum_{n=-\infty}^{\infty} x[n] (e^{-j2\pi n})^{f T_s}$$

Hodnota spektra na frekvenci $f + f_s$:

$$\begin{aligned} X(f + f_s) &= \sum_{n=-\infty}^{\infty} x[n] (e^{-j2\pi n})^{(f+f_s)T_s} = \sum_{n=-\infty}^{\infty} x[n] (e^{-j2\pi n})^{(fT_s+1)} \\ &= \sum_{n=-\infty}^{\infty} x[n] (e^{-j2\pi n})^{fT_s} \cdot \underbrace{(e^{-j2\pi n})}_{=1} = X(f) \end{aligned}$$

Spektrum diskrétního signálu $X(e^{j\theta})$ je periodické: $T_\theta = 2\pi$, $T_f = f_s$

Spektrum diskrétního signálu - periodicitá

Vzorkovací funkce:

$$s(t) = \sum_{n=-\infty}^{\infty} \delta(t - nT_s) \quad T_s = \frac{1}{f_s}$$

Vzorkování signálu $x(t)$ (násobení vzorkovací funkcí):

$$x_s(t) = x(t) \cdot s(t) = x(t) \sum_{n=-\infty}^{\infty} \delta(t - nT_s) = \sum_{n=-\infty}^{\infty} x(nT_s) \delta(t - nT_s)$$

Spektrum diskrétního signálu (násobení se transformuje na konvoluci)

$$X_s(f) = X(f) \star S(f)$$

Spektrum vzorkovací funkce:







$$S(f) = 2\pi f_s \sum_{k=-\infty}^{\infty} \delta(f - kf_s)$$

Spektrum diskrétního signálu

$$X_s(f) = X(f) \star S(f) = \sum_{k=-\infty}^{\infty} X(f - kf_s)$$



Výsledek konvoluce - spektrum diskrétního signálu $X_s(f)$ obsahuje periodické repliky spektra spojitého signálu $X(f)$ na kmitočtech kf_s (na celočíselných násobcích f_s)

Spektrum diskrétního signálu - periodicitá





Vzorkovací teorém

Správné vzorkování : $f_s > 2f_{\max}$





Špatné vzorkování : $f'_s < 2f_{\max}$





→ spektrum je zkresleno díky překryvům

Vzorkovací teorém (vzorkování sinusovky)

Správné vzorkování : $f_s/2 > f_{sine}$




Špatné vzorkování : $f'_s/2 < f_{sine}$



Vzorkovací teorem

- **základní formulace:** $f_s > 2 \cdot f_{max}$
 - vzorkovací frekvence musí být dostatečně velká podle maximální frekvence obsažené v signálu
- **jiná formulace:** $f_{max} < \frac{f_s}{2}$
 - horní hranice frekvenčního pásma musí být omezena podle použité vzorkovací frekvence
 - aplikace **antialiasingového filtru** (dolní propusti)
 - frekvenční obsah nad $\frac{f_s}{2}$ je potlačen (typický přístup)




POZN: Tato základní formulace platí pro **nízko-frekvenční signály** (tj. frekvenční pásmo obsahuje $f = 0$).

Vzorkování pásmových signálů bude diskutováno později v semestru.


Vzorkování a kvantování - diskrétní vs. číslicový signál

Diskretizace na časové úrovni ... vzorkování → **diskrétní signál**

$x(t)$... spojitý signál




$x[n]$... diskrétní signál




Diskretizace na úrovni vzorku (kvantizace)

... vzorkování + kvantizace → **číslcový signál**

$x(t)$... spojitý signál



$x_d[n]$... číslicový signál



Číslicová reprezentace :

- používá se v realizacích číslicových systémů
- pro uchování dat, různé formáty a přesnosti (tj. počet bitů na vzorek a vzorkovací frekvence)
- podpora čtení a ukládání různých formátů je standardem

Číslicové signály v MATLABu :

- **vysoké rozlišení** pro vzorky signálu (MATLAB používá plovoucí čárku a double reprezentaci)
- téměř **diskrétní signál** v plné přesnosti (zejména při zpracování resp. při výpočtu mezivýsledků)

***POZN.1** - Detaily hardwarové realizace převodu spojitého signálu na číslicový (AD převodníky) nebudou v tomto předmětu diskutovány.*

***POZN.2** - Důsledky kvantizace mezivýsledků při realizaci číslicových systémů budou diskutovány v souvislosti s návrhy číslicových filtrů.*


Část II

Diskrétní signály deterministické a stochastické

Deterministické diskrétní signály

Deterministické signály jsou dané přesným popisem
(vzorec pro generování, analytický popis každého vzorku)

Příklady: *sinusovka, exponenciální puls, jednotkový skok, jednotkový impuls, obecný periodický signál (harmonická struktura), odezvy diskrétních systémů*



Deterministický signál **je reprodukovatelný** (opakovatelné generování)


Charakteristiky mohou být **odhadovány** z **jedné realizace**

Náhodné diskrétní signály

Náhodné (stochastické) signály

- analytický popis hodnoty jednotlivých vzorků neexistuje
- hodnoty vzorků jsou popsány hustotou pravděpodobnosti (pdf)
- jednotlivé realizace náhodného signálu nejsou opakovatelné
- náhodný signál není reprodukovatelný


Příklad 1: Gaussovský bílý šum



PDF Gaussovského bílého šumu:

$$p(x) = \frac{1}{\sqrt{2\pi\sigma_x^2}} \cdot \exp\left(-\frac{(x - \mu_x)^2}{2\sigma_x^2}\right)$$

Příklad 2: Bílý šum s rovnoměrným rozdělením



PDF bílého šumu s rovnoměrným rozdělením:

$$p(x) = \begin{cases} \frac{1}{x_{\max} - x_{\min}} & \text{pro } x_{\min} \leq x \leq x_{\max} \\ 0 & \text{otherwise} \end{cases}$$

Další příklady: barevný šum, neznělá řeč

Odhady **charakteristik náhodných signálů:**


- ovlivněny náhodnou chybou odhadu
- minimalizace chyby odhadu - odhady z delší části signálu
- odhady z více realizací

Diskrétní signály s deterministickou a náhodnou složkou

Kombinace náhodné a deterministické složky

Lehká variabilita periodického signálu, šum na pozadí

Příklady: *znělá řeč (lehká variabilita harmonické struktury), EKG, EEG*



Odhady charakteristik analogické náhodných signálů:

- náhodná chyba odhadu se potlačuje
- deterministická složka je zvýrazněna

Část III
Základní časové charakteristiky
diskrétních signálů

Základní časové charakteristiky diskrétních náhodných signálů

Definice pro spojitý čas

Střední hodnota

$$\mu_{x,k} = Av[x_k(t)] = \lim_{T \rightarrow \infty} \frac{1}{T} \int_{-T/2}^{T/2} x_k(t) dt \dots \text{empirická střední hodnota (přes čas)}$$

$$\mu_x(t) = E[x_k(t)] = \int_{-\infty}^{\infty} x(t) p(x, t) dx \dots \text{pravděpodobnostní střední hodn. (přes realizace) - expected value}$$

Definice pro diskrétní čas

Střední hodnota

$$\mu_{x,k} = Av[x_k[n]] = \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{n=-N/2}^{N/2-1} x_k[n] \dots \text{empirická střední hodnota (přes diskrétní čas)}$$

$$\mu_x[n] = E[x_k[n]] = \sum_{k=-\infty}^{\infty} x_k[n] p(x_k[n]) \dots \text{pravděpodobnostní střední hodn. (přes realizace)}$$

Odhady střední hodnoty diskrétního signálu

Odhad empirické střední hodnoty konečného počtu vzorků

$$\hat{\mu}_{x,k} = \frac{1}{N} \sum_{n=0}^{N-1} x_k[n]$$

→ empirická hodnota = empirický odhad z jedné realizace

Odhad pravděpodobnostní střední hodnoty

$$\hat{\mu}_x[n] = \sum_{k=0}^{K-1} x_k[n] p(x_k[n])$$

- pdf musí být dostupné nebo odhadnuté pomocí histogramu


Pozn. 1 Pro odhady z 1. realizace konečné délky N resp. z konečného počtu realizací K

- odhady mají také náhodný charakter (náhodná chyba odhadu)
- chyba odhadu závisí na N resp. K

Pozn. 2 Odhady charakteristik deterministických signálů náhodnou chybu neobsahují, signál je vždy stejný, možná nenáhodná chyba daná výběrem



Empirická střední hodnota náhodného signálu

$$\hat{\mu}_{x,k} = \frac{1}{N} \sum_{n=0}^{N-1} x_k[n] \quad \dots \text{nezávislá na čase, závislá na realizaci}$$



Pravděpodobnostní střední hodnota náhodného signálu

$$\hat{\mu}_x[n] = \sum_{k=0}^{K-1} x_k[n] p(x_k[n]) \quad \dots \text{závislá na čase, nezávislá na realizaci}$$




Příklad odhadu pravděpodobnostní střední hodnoty


Výška mladých mužů v ČR

(odhad z přítomných studentů v posluchárně)

simulovaná pdf (hustota pravd.)



histogram (numerický odhad pdf)



Odhadovaná průměrná výška je kolem 180 cm

Histogram - lze odhadnout i v méně třídách různé šířky

Výška mladých mužů v ČR - EMPIRICKÝ ODHAD

Standardní přístup:

(záznam všech hodnot a výpočet empirické hodnoty)

$x = [172, 181, 176, 169, \dots, 171]$

$$\hat{\mu}_x = \frac{1}{N} \sum_{n=1}^N x[n] = \frac{1}{N} (172 + 181 + 176 + 169 + \dots + 171) =$$

Nevhodný a příliš pracný přístup pro ruční výpočet a vysoké N .

Příklad odhadu pravděpodobnostní střední hodnoty

Výška mladých mužů v ČR - PRAVDĚPODOBNOSTNÍ ODHAD
(záznam četností ve skupinách, odhad pdf, výpočet stř. hodnoty)

Skupina	hranice 1	hranice 2	četnosti	x_k	p_k
1	160	170		165.0	
2	170	175		172.5	
3	175	180		177.5	
4	180	185		182.5	
5	185	190		187.5	
6	190	200		195.0	
všichni	—	—		—	—

$$\hat{\mu}_{x,prob} = \sum_{k=1}^6 x_k p_k =$$

Příklad aplikace pravděpodobnostních odhadů:

iterativní odhady parametrů HMM (Baum-Welch) - příslušnost ke třídě je dána postupně zpřesňovnou pravděpodobností (okupační věrohodností) - více v budoucích předmětech

Ergodicita diskrétního signálu

Definice střední hodnoty

$$\mu_{x,k} = Av[x_k[n]] = \lim_{N \rightarrow \infty} \frac{1}{N} \sum_{n=-N/2}^{N/2-1} x_k[n] \dots \text{empirická}$$
$$\mu_x[n] = E[x_k[n]] = \sum_{k=-\infty}^{\infty} x_k[n] p(x_k[n]) \dots \text{pravděpodobnostní}$$

Náhodný signál je **ergodický** (vzhledem ke střední hodnotě), když platí:

$$E[x_k[n]] = Av[x_k[n]]$$




Střední hodnota může být odhadnuta empiricky z jedné libovolné realizace


$$\hat{\mu}_x = \hat{\mu}_x[n] = \hat{\mu}_{x,k} = \frac{1}{N} \sum_{n=0}^{N-1} x[n]$$

Pozn. Ergodicita se vztahuje vždy k odhadu vybrané charakteristiky!

Stacionární náhodný signál ergodický vůči střední hodnotě




Stacionární signál neergodický vůči střední hodnotě



Příklad: odhad formantů řeči - neergodický proces

Rozložení F1 a F2 pro mluvčího A:




Shluky pro jednotlivé hlásky jsou oddělené

- lze počítat střední hodnotu pro reprezentaci hlásky

Příklad: odhad formantů řeči - neergodický proces


Rozložení F1 a F2 pro mluvčího B:



Shluky pro jednotlivé hlásky
- stále oddělené ale posunuté

Příklad: odhad formantů řeči - neergodický proces


Rozložení F1 a F2 pro mluvčí A a B:



Shluky pro jednotlivé hlásky jsou oddělené, tj. odhad střední hodnoty formantu je pro různé mluvčí různý → neergodický proces

Příklad: odhad formantů řeči - neergodický proces

Rozložení F1 a F2 pro více mluvčích:





Řeč je pro různé mluvčí neergodický signál z hlediska spektra

→ parametry statistických modelů pro rozpoznávání je nutné odhadnout z databáze promluv mnoha řečníků

Neergodicita řeči pro realizace v různých podmínkách

Charakteristiky (spektrální/formanty) se výrazně mění pro různé podmínky snímání resp. produkce → řeč je obecně neergodická



- Lombardův jev = změna charakteristik hlasu při produkci řeči v hlučném prostředí
- podobně pro produkci řeči ve stresu či pod různými emocemi



Neergodicitu řeči (z hlediska mluvčích, prostředí resp. podmínek produkce, apod.) je nutné zohledňovat při tvorbě modelů pro různé klasifikační účely (rozpoznávání)

Další základní časové charakteristiky náhodných signálů

- Rozptyl (variance) (střední kvadratická odchylka)

$$\sigma_x^2 = Av[(x[n] - \mu_x)^2] \qquad \hat{\sigma}_x^2 = \frac{1}{N} \sum_{n=0}^{N-1} (x[n] - \hat{\mu}_x)^2$$

- Standardní odchylka

$$\sigma_x = \sqrt{Av[(x[n] - \mu_x)^2]} \qquad \hat{\sigma}_x = \sqrt{\frac{1}{N} \sum_{n=0}^{N-1} (x[n] - \hat{\mu}_x)^2}$$

- Výkon signálu (střední kvadratická hodnota)

$$P_x = Av[x^2[n]] \qquad \hat{P}_x = \frac{1}{N} \sum_{n=0}^{N-1} x^2[n]$$

- Energie

$$E_x = \sum_{n=0}^{N-1} x^2[n]$$

Energie je definovaná pouze pro signály konečné délky!

- Odstup signálu od šumu (Signal-to-Noise-Ratio)

pro signály se šumovým pozadím - $x[n] = s[n] + n[n]$

$$SNR_x = 10 \cdot \log_{(10)} \frac{P_s}{P_n}$$

Děkuji za pozornost!